

Duplicatas, ausências e tratamento de dados

Bases avaliadas: PIB Municipal (5938), PAM (5457) e PPM (3939) — IBGE/SIDRA

DUPLICATAS

Checado pela chave primária oficial de cada base (território + ano + variável, com desdobramento de produto/rebanho quando existe).

0

duplicatas — PIB

0

duplicatas — PAM (5 arquivos)

0

duplicatas — PPM

AUSÊNCIAS (NaN nativo)

Nenhuma célula vazia em nenhuma das 3 bases — todo dado ausente vem como símbolo de texto, nunca célula em branco. `isna()` cru retorna zero em tudo; o N/A real só aparece depois de tratar o símbolo (seção seguinte).

0 NaN nativo nas 3 bases

mas o dado ausente existe — disfarçado de texto

Símbolos especiais, símbolo a símbolo

Base	Símbolo	Ocorrências	%	Significado
PIB	"..."	1.116	7,1%	indisponibilidade temporal — 2022/2023 ainda não fechados pelo IBGE
PAM	"-"	31.467	22,0%	estrutural — produto não cultivado no município (Melão ausente em 162/184)
PAM	"0" (texto)	6	<0,01%	zero explícito, só no arquivo valor_producao
PPM	"_"	5	0,02%	residual — só Ovino/Município, 2017-2021

Diferença-chave:

"-" (PAM/PPM) é estrutural — ausência de atividade. "..." (PIB) é lacuna temporal de apuração. Tratar os dois do mesmo jeito estaria errado.

Decisões de tratamento

1

"-" (PAM e PPM) → fillna(0)

No padrão SIDRA, "-" significa zero exato (não cultivado / não criado), não "sem informação". Converter para NaN geraria viés — perderia linhas válidas em análises que exigem valor numérico.

2

"..." (PIB) → NaN

Representa indisponibilidade real de apuração (2022/2023 ainda não fechados). Não pode virar zero — mentiria sobre o dado, sugerindo PIB zero quando na verdade é desconhecido.

3

territorio_codigo → string, não int

Preserva os 7 dígitos do código IBGE de município — evita truncar ou perder zero à esquerda em qualquer reformatação futura.

4

Conversão sempre via pd.to_numeric(..., errors="coerce")

Aplicado antes de qualquer cálculo — nunca usar a coluna valor bruta (chega como texto/object nas 3 bases).

5

Rastreabilidade

Tratamento aplicado em código, a partir dos arquivos raw, sem sobrescrever o dado original — reproduzível do zero a qualquer momento.