

Inventario de Dados - PIB Agropecuaria do Ceara

Fonte: IBGE/SIDRA, tabela 5938

Arquivo: t5938_pib_agropecuaria_2003_2023_ce_br.csv

Periodo: 2003-2023

Ficha tecnica

linhas: 15624

colunas: 10

territorios: 186 (Brasil, Ceara, 184 municipios)

anos: 21 (2003-2023)

variaveis: 4

duplicatas: 0

Variaveis presentes:

37 - Produto Interno Bruto a precos correntes (Mil Reais)

498 - Valor adicionado bruto total (Mil Reais)

513 - Valor adicionado bruto da agropecuaria (Mil Reais)

516 - Participacao da agropecuaria no VAB total (%)

1. Estrutura e schema

Formato longo: cada linha = territorio x ano x variavel.

Colunas:

nivel_territorial_codigo	texto	N1/N3/N6 (Brasil/UF/Municipio)
nivel_territorial_nome	texto	nome do nivel
territorio_codigo	inteiro	chave de juncao IBGE (186 valores)
territorio_nome	texto	municipios com sufixo " - CE"
ano_codigo / ano_nome	inteiro	identicas nesta tabela
variavel_codigo/_nome	int/texto	qual das 4 variaveis
unidade	texto	"Mil Reais" ou "%"
valor	texto	precisa tratamento (secao 2)

Checagem de mapeamento codigo <-> nome:

nivel_territorial_codigo -> nivel_territorial_nome: 1:1 OK

variavel_codigo -> variavel_nome: 1:1 OK

2. Dados faltantes

A coluna valor chega como texto. O IBGE usa o marcador "..." para dado nao disponivel em vez de celula vazia. Isso mascara o N/A de qualquer checagem ingenua (isna() retorna zero antes da conversao com pd.to_numeric(errors="coerce")).

Total de linhas afetadas: 1116 (7.1% do total)

Por variavel:

VAB total	372
VAB agropecuaria	372
Participacao (%)	372

Por ano:

2022	558
2023	558



Por nivel territorial:

Municipio	1104
Brasil	6
Unidade da Federacao	6

O PIB bruto (variavel 37) esta 100% completo em todos os anos.


Interpretacao: 2022/2023 ainda sem fechamento municipal completo das contas regionais - defasagem normal do IBGE, nao erro.

3. Distribuicao do PIB municipal (2023)



Em escala linear a distribuicao parece um unico pico junto do zero (cauda longa extrema). Em escala log fica visivel a distribuicao real entre os 184 municipios.

4. Evolucao do PIB - Ceara x top 10 municipios (2003-2023)



O distanciamento entre Fortaleza e os demais municipios e estrutural ao longo de toda a serie, nao um evento pontual.

5. Outliers

IQR calculado separadamente por nível territorial (misturar Brasil/UF/Município distorce o limite: Brasil tem PIB da ordem de trilhões, município da ordem de milhões).

Outliers por variável (nível Município):

PIB	442 de 3864
VAB total	397 de 3496
VAB agropecuária	254 de 3496
Participação (%)	79 de 3496

Brasil e Unidade da Federação: 0 a 4 outliers (séries curtas e homogêneas, 19-21 pontos cada).

Antes x depois de remover outlier de PIB (so diagnóstico, outlier NAO foi removido do dataset de trabalho):

antes:	n=3864	media=616.139	desvio=3.940.754	max=86.939.832
depois:	n=3422	media=159.833	desvio=142.560	max=659.097

(valores em Mil Reais; removidos = 442, 11.4%)

Top outliers = Fortaleza em praticamente todos os anos da série (2014 a 2023, de R\$6,1 mi a R\$87 mi). Concentração econômica real, não erro de coleta.

Decisão do time: outliers MANTIDOS no dataset de trabalho.

6. Consistencia interna e chaves de juncao

Checks de consistencia:

- [OK] ano_codigo == ano_nome em 100% das linhas
- [OK] 186 territorios x 21 anos x 4 variaveis = 15624 linhas (bate)
- [OK] cada um dos 184 municipios tem exatamente 84 linhas
(21 anos x 4 variaveis) - sem buraco estrutural
- [OK] todo territorio_nome de municipio termina em " - CE";
Brasil e Ceara nunca tem o sufixo

Chave de juncao recomendada: territorio_codigo + ano_nome

Compatibilidade com as outras fontes do projeto:

- PAM (area colhida) 186 codigos, 186 em comum com PIB
- PPM (efetivo rebanhos) 186 codigos, 186 em comum com PIB
- Malha municipal (geojson) 184 codigos, 184 em comum com PIB
(diferenca de 2 = Brasil e Ceara, esperado: geojson so cobre municipio)

7. Conclusao

O dataset e estruturalmente solido: zero duplicatas, cobertura territorial e temporal completa, chaves de juncao validadas contra as outras 3 fontes do projeto (PAM, PPM, malha municipal).

Tratamento obrigatorio antes de qualquer analise:

```
df["valor"] = pd.to_numeric(df["valor"], errors="coerce")  
(sem isso, isna().sum() nao acusa os 1116 N/A reais)
```

Outliers nao foram removidos - refletem concentracao economica real (Fortaleza e polos regionais). Analises subsequentes devem tratar essa assimetria de proposito (escala log, mediana em vez de media).